

Proyecto 1: Competencia de Modelación de Deep Learning

Predicción de Precios de Viviendas mediante Ensamblés Multi-Semilla de Tabular ResNet y SwiGLU MLP

CC3092 - Deep Learning y Sistemas Inteligentes
Universidad del Valle de Guatemala

Agosto 2026

Resumen

Este informe presenta el desarrollo de un sistema de aprendizaje profundo basado en Redes Neuronales Multicapa (*Multi-Layer Perceptrons*) para la predicción de precios de venta de viviendas residenciales en Ames, Iowa. A través de un riguroso análisis exploratorio de datos, se implementó un pipeline de preprocesamiento e ingeniería de variables dominiales que incluye agregaciones de superficie, edades efectivas e interacciones no lineales. Se evaluaron arquitecturas estándar, Wide & Deep, Tabular ResNet-MLP y SwiGLU-MLP. El modelo final consiste en un ensamble de 60 modelos neuronales entrenados mediante validación cruzada estratificada de 10 pliegues y 3 semillas aleatorias independientes, minimizando la función de pérdida *Smooth L1 Loss* (Huber) en escala logarítmica. El ensamble alcanzó un error de generalización fuera de muestra (OOF RMSE) de \$26,772.24, un R^2 de 0.8798 y un MAPE de 7.96 %, proporcionando alta robustez ante datos no observados.

Índice

1. Análisis Exploratorio de Datos (EDA)	2
1.1. Dimensiones del Dataset y Distribución de Tipos de Variables	2
1.2. Análisis de la Variable Objetivo: SalePrice	2
1.3. Variables Más Correlacionadas e Ingeniería de Características	2
1.4. Decisiones de Preprocesamiento Basadas en el EDA	3
2. Metodología de Desarrollo	3
2.1. Arquitecturas de Red Evaluadas	3
2.2. Estrategia de Validación Cruzada, Regularización y Ensamble	4
3. Resultados y Comparativa de Modelos	4
4. Discusión de Resultados	5
4.1. Análisis de Errores y Residuos	5
4.2. Trade-off entre Complejidad y Generalización	5
5. Conclusiones	5
6. Instrucciones para Inferencia en el Día de la Presentación	5

1. Análisis Exploratorio de Datos (EDA)

1.1. Dimensiones del Dataset y Distribución de Tipos de Variables

El conjunto de entrenamiento provisto contiene un total de 1,168 observaciones y 81 columnas:

- **Identificador:** Columna Id.
- **Variable Objetivo:** SalePrice (continua positiva).
- **Variables Predictoras:** 79 características, distribuidas en 36 variables numéricas continuas/discretas y 43 variables categóricas (nominales y ordinales).

1.2. Análisis de la Variable Objetivo: SalePrice

La distribución original de SalePrice presenta una asimetría positiva sustancial (skewness = 1.88) y colas pesadas (kurtosis = 6.53), con precios que oscilan entre \$34,900 y \$745,000 (media: \$181,441; mediana: \$165,000). Para adecuar los datos al entrenamiento de redes neuronales y estabilizar la varianza del gradiente, se aplicó la transformación logarítmica:

$$y_{\text{trans}} = \log(1 + \text{SalePrice}) \quad (1)$$

La Figura 1 ilustra la distribución original y la distribución normalizada tras la transformación.




Figura 1: Distribución de la variable objetivo antes y después de la transformación logarítmica.

1.3. Variables Más Correlacionadas e Ingeniería de Características

Las variables numéricas con mayor correlación lineal con el precio de venta son OverallQual ($r = 0.79$), GrLivArea ($r = 0.71$), GarageCars ($r = 0.64$), GarageArea ($r = 0.62$), TotalBsmtSF ($r = 0.61$) y 1stFlrSF ($r = 0.60$).




Figura 2: Matriz de correlación de las principales variables numéricas con **SalePrice**.

1.4. Decisiones de Preprocesamiento Basadas en el EDA

1. **Imputación de Valores Faltantes por Dominio:** En variables como **Alley**, **BsmtQual**, **GarageType**, **FireplaceQu** y **PoolQC**, los valores nulos (NA) indican la ausencia física del elemento. Fueron imputados como la categoría explícita 'None'.
2. **Imputación de LotFrontage:** Mediana agrupada por vecindario (**Neighborhood**).
3. **Ingeniería de Características Avanzada:**

$$\text{TotalSF} = \text{TotalBsmtSF} + \text{1stFlrSF} + \text{2ndFlrSF} \quad (2)$$

$$\text{TotalFinishedSF} = \text{1stFlrSF} + \text{2ndFlrSF} + \text{BsmtFinSF1} + \text{BsmtFinSF2} \quad (3)$$

$$\text{TotalBath} = \text{FullBath} + 0.5 \times \text{HalfBath} + \text{BsmtFullBath} + 0.5 \times \text{BsmtHalfBath} \quad (4)$$

$$\text{TotalPorchSF} = \text{WoodDeckSF} + \text{OpenPorchSF} + \text{EnclosedPorch} + 3\text{SsnPorch} + \text{ScreenPorch} \quad (5)$$

$$\text{HouseAge} = \max(0, \text{YrSold} - \text{YearBuilt}) \quad (6)$$

$$\text{OverallGrade} = \text{OverallQual} \times \text{OverallCond} \quad (7)$$

4. **Codificación y Escalamiento:** Calificaciones ordinales mapeadas a enteros (5 a 0), One-Hot Encoding para nominales con diccionario fijo de categorías, y **RobustScaler** para numéricas.

2. Metodología de Desarrollo

2.1. Arquitecturas de Red Evaluadas

Se implementaron y compararon cuatro familias de arquitecturas profundas para datos tabulares:

1. **Standard Deep MLP:** Capas lineales densas con *BatchNorm1d*, activación GELU y *Dropout*.
2. **Wide & Deep MLP:** Integración de conexiones lineales amplias con bloques densos no lineales.
3. **Tabular ResNet-MLP:** Bloques residuales profundos con *LayerNorm* y conexiones de acceso directo (*skip connections*):

$$x_{l+1} = \text{GELU}\left(\text{FC}_2\left(\text{Dropout}\left(\text{GELU}\left(\text{FC}_1\left(\text{LayerNorm}(x_l)\right)\right)\right) + x_l\right)\right) \quad (8)$$

4. **SwiGLU-MLP:** Red con unidades lineales compuerta con activación Swish (*Swish Gated Linear Units*), permitiendo modular dinámicamente el flujo de información en datos tabulares:

$$\text{SwiGLU}(x) = \text{FC}_{\text{out}}\left(\text{Dropout}\left(\text{SiLU}\left(\text{FC}_{\text{gate}}\left(\text{LayerNorm}(x)\right)\right) \odot \text{FC}_{\text{val}}\left(\text{LayerNorm}(x)\right)\right)\right) + x \quad (9)$$

2.2. Estrategia de Validación Cruzada, Regularización y Ensamble

- **10-Fold Cross-Validation:** El dataset se dividió en 10 pliegues independientes. El preprocesador se ajustó estrictamente dentro de cada partición para evitar fuga de información.
- **Función de Pérdida:** *Smooth L1 Loss* (Huber Loss con $\beta = 0.02$) en escala logarítmica.
- **Aumento de Datos Tabular:** Tabular Mixup aplicado durante entrenamiento ($\alpha = 0.3$) con probabilidad de 25 %.
- **Optimizador y Planificador:** AdamW ($\text{lr} = 8 \times 10^{-4}$, $\text{weight_decay} = 10^{-4}$) con *CosineAnnealingWarmRestarts* ($T_0 = 50$, $T_{\text{mult}} = 2$).
- **Ensamble Multi-Arquitectura y Multi-Semilla:** Promediado ponderado de 60 modelos resultantes de 2 arquitecturas (*ResNet* y *SwiGLU*) evaluadas en 3 semillas aleatorias (42, 123, 2024) y 10 pliegues cada una.


3. Resultados y Comparativa de Modelos

En la Tabla 1 se detalla la progresión del error Out-Of-Fold en las distintas fases de modelación.


Cuadro 1: Resumen comparativo de arquitecturas y modelos evaluados.

Arquitectura	Estrategia de Validación	OOF RMSE (\$)	R^2 Score	Observaciones
Standard MLP	5-Fold CV	86,843.36	0.4412	Inestabilidad
Wide & Deep MLP	5-Fold CV	45,907.44	0.7180	Mejora p
Tabular ResNet-MLP	5-Fold CV	27,191.41	0.8650	Skip con
SwiGLU-MLP	5-Fold CV	27,621.55	0.8621	Excelent
Ensamble Multi-Semilla (60 Modelos)	10-Fold CV (3 Seeds)	26,772.24	0.8798	Modelo

Las Figuras 3a y 3b muestran el ajuste del ensamble final y la distribución de sus residuos Out-of-Fold.



(a) Precios Reales vs. Predichos (\$)



(b) Análisis de Errores Residuos

Figura 3: Evaluación de desempeño fuera de muestra del ensamble final.

4. Discusión de Resultados

4.1. Análisis de Errores y Residuos

El ensamble final alcanzó las siguientes métricas globales fuera de muestra:

- **RMSE: \$26,772.24**
- **MAE: \$13,627.83**
- **R^2 Score: 0.8798**
- **MAPE: 7.96 %**

Los residuos se encuentran centrados en cero con dispersión simétrica. El error porcentual promedio (MAPE) de 7.96 % confirma que el modelo predice con alta precisión el valor comercial de las viviendas en la gran mayoría de rangos de precio.

4.2. Trade-off entre Complejidad y Generalización

Las redes neuronales densas convencionales sobreajustan rápidamente en datos tabulares de dimensión moderada. El uso de conexiones residuales, unidades SwiGLU, regularización por *Dropout* y promediado de múltiples semillas aleatorias reduce la varianza del estimador y maximiza la generalización ante el conjunto de prueba de la competencia.

5. Conclusiones

1. ****Rendimiento Competitivo****: El ensamble neuronal de 60 modelos alcanza un MAPE de 7.96 % y un R^2 de 0.8798. 2. ****Impacto de la Ingeniería de Características****: La creación de variables agregadas (`TotalFinishedSF`, `TotalBath`) y el preprocesamiento robusto fueron fundamentales. 3. ****Superioridad de ResNet y SwiGLU****: Las arquitecturas residuales y de compuertas superaron sustancialmente al perceptrón multicapa clásico.

6. Instrucciones para Inferencia en el Día de la Presentación

Para generar las predicciones sobre el dataset de prueba el día de la presentación, ejecute desde la raíz del proyecto:

```
1 python main.py predict --test_path data/pruebas/pipeline_test.csv --output_path  
   data/pruebas/expected_output.csv
```

El script cargará automáticamente el preprocesador (`data/saved_models/pipeline.joblib`) y los 60 modelos del ensamble (`data/saved_models/model_*.pt`), generando el archivo CSV en el formato exacto requerido (`Id,Prediction`).