

Proyecto 1: Competencia de Modelación de Deep Learning

Predicción de Precios de Viviendas mediante Redes Neuronales Residuales (Tabular ResNet-MLP)

CC3092 - Deep Learning y Sistemas Inteligentes
Universidad del Valle de Guatemala

Agosto 2026

Resumen

Este informe presenta el desarrollo, experimentación y despliegue de un sistema de aprendizaje profundo basado en Redes Neuronales Multicapa (*Multi-Layer Perceptrons*) para la predicción del precio de venta de viviendas residenciales en Ames, Iowa. A través de un análisis exploratorio riguroso, se diseñó un pipeline de preprocesamiento robusto que imputa datos faltantes según el dominio, codifica variables ordinales y nominales, y construye características compuestas clave. Se evaluaron múltiples arquitecturas (Standard MLP, Wide & Deep, SwiGLU y Tabular ResNet). Tras analizar el riesgo de sobreajuste (*overfitting*) intrínseco en ensambles de alta complejidad, se seleccionó un único modelo definitivo: ****Tabular ResNet-MLP**** con 2 bloques residuales, normalización por capas (*LayerNorm*) y *Dropout* del 20 %, optimizado bajo *Smooth L1 Loss* (Huber) en escala logarítmica. Este modelo alcanza un error cuadrático medio fuera de muestra (OOF RMSE) de **\$24,953.61**, un coeficiente de determinación R^2 de **0.8956** y un MAPE de **8.10 %**, garantizando máxima capacidad de generalización y un despliegue liviano y determinista en un único archivo de pesos (**model.pt**).

Índice

1. Análisis Exploratorio de Datos (EDA)	2
1.1. Dimensiones del Dataset y Distribución de Tipos de Variables	2
1.2. Análisis de la Variable Objetivo: SalePrice	2
1.3. Variables Más Correlacionadas e Ingeniería de Características	2
1.4. Decisiones de Preprocesamiento Basadas en el EDA	3
2. Metodología de Desarrollo	3
2.1. Arquitectura Seleccionada: Tabular ResNet-MLP	3
2.2. Estrategia de Entrenamiento y Regularización	4
3. Resultados de Iteraciones y Comparativa de Modelos	4
4. Discusión de Resultados	5
4.1. Análisis del Trade-off Complejidad vs. Sobreajuste (Overfitting)	5
4.2. Análisis de Errores y Residuos	5
5. Conclusiones	5
6. Instrucciones para Inferencia en el Día de la Presentación	5

1. Análisis Exploratorio de Datos (EDA)

1.1. Dimensiones del Dataset y Distribución de Tipos de Variables

El conjunto de entrenamiento provisto contiene un total de 1,168 observaciones y 81 columnas:

- **Identificador:** Columna Id.
- **Variable Objetivo:** SalePrice (continua positiva).
- **Variables Predictoras:** 79 características, distribuidas en 36 variables numéricas continuas/discretas y 43 variables categóricas (nominales y ordinales).

1.2. Análisis de la Variable Objetivo: SalePrice

La distribución original de SalePrice presenta una asimetría positiva sustancial (skewness = 1.88) y colas pesadas (kurtosis = 6.53), con precios que oscilan entre \$34,900 y \$745,000 (media: \$181,441; mediana: \$165,000). Para adecuar los datos al entrenamiento de redes neuronales y estabilizar la varianza del gradiente, se aplicó la transformación logarítmica:

$$y_{\text{trans}} = \log(1 + \text{SalePrice}) \quad (1)$$

La Figura 1 ilustra la distribución original y la distribución normalizada tras la transformación.




Figura 1: Distribución de la variable objetivo antes y después de la transformación logarítmica.

1.3. Variables Más Correlacionadas e Ingeniería de Características

Las variables numéricas con mayor correlación lineal con el precio de venta son OverallQual ($r = 0.79$), GrLivArea ($r = 0.71$), GarageCars ($r = 0.64$), GarageArea ($r = 0.62$), TotalBsmtSF ($r = 0.61$) y 1stFlrSF ($r = 0.60$).




Figura 2: Matriz de correlación de las principales variables numéricas con **SalePrice**.

1.4. Decisiones de Preprocesamiento Basadas en el EDA

1. **Imputación de Valores Faltantes por Dominio:** En variables como **Alley**, **BsmtQual**, **GarageType**, **FireplaceQu** y **PoolQC**, los valores nulos (NA) indican la ausencia física del elemento. Fueron imputados como la categoría explícita 'None'.
2. **Imputación de LotFrontage:** Mediana agrupada por vecindario (**Neighborhood**).
3. **Ingeniería de Características:**

$$\text{TotalSF} = \text{TotalBsmtSF} + \text{1stFlrSF} + \text{2ndFlrSF} \quad (2)$$

$$\text{TotalBath} = \text{FullBath} + 0.5 \times \text{HalfBath} + \text{BsmtFullBath} + 0.5 \times \text{BsmtHalfBath} \quad (3)$$

$$\text{TotalPorchSF} = \text{WoodDeckSF} + \text{OpenPorchSF} + \text{EnclosedPorch} + 3\text{SsnPorch} + \text{ScreenPorch} \quad (4)$$

$$\text{HouseAge} = \max(0, \text{YrSold} - \text{YearBuilt}) \quad (5)$$

$$\text{RemodAge} = \max(0, \text{YrSold} - \text{YearRemodAdd}) \quad (6)$$

$$\text{Qual}_x\text{-TotalSF} = \text{OverallQual} \times \text{TotalSF} \quad (7)$$

4. **Codificación y Escalamiento:** Calificaciones ordinales mapeadas a enteros (5 a 0), One-Hot Encoding para nominales con diccionario cerrado, y **RobustScaler** para numéricas con transformación $\log(1 + x)$ para variables asimétricas ($\text{skew} > 0.75$), generando 248 características consolidadas.

2. Metodología de Desarrollo

2.1. Arquitectura Seleccionada: Tabular ResNet-MLP

La arquitectura definitiva consiste en una red neuronal profunda con bloques residuales (*Residual Blocks*), normalización por capas (*LayerNorm*), activaciones GELU y conexiones de

acceso directo (*skip connections*):

$$x_{l+1} = \text{GELU}\left(\text{FC}_2\left(\text{Dropout}\left(\text{GELU}\left(\text{FC}_1\left(\text{LayerNorm}(x_l)\right)\right)\right) + x_l\right)\right) \quad (8)$$

La red contiene 2 bloques residuales de dimensión 512, regularización por *Dropout* al 20% y una capa lineal de salida directa.

2.2. Estrategia de Entrenamiento y Regularización

- **Estrategia de Validación:** Validación cruzada de 10 pliegues (*10-Fold CV*) para garantizar una medición insesgada del error fuera de muestra.
- **Función de Pérdida:** *Smooth L1 Loss* (Huber Loss) aplicada sobre $\log(1 + y)$, otorgando robustez ante transacciones atípicas.
- **Optimizador y Planificador:** AdamW ($\text{lr} = 7.42 \times 10^{-4}$, $\text{weight_decay} = 2.39 \times 10^{-4}$) con planificador *CosineAnnealingLR* ($T_{\text{máx}} = 120$).
- **Detención Temprana:** *Early Stopping* con paciencia de 30 épocas monitoreando el error de validación.


3. Resultados de Iteraciones y Comparativa de Modelos

En la Tabla 1 se detalla la progresión del error en las distintas fases experimentales.


Cuadro 1: Resumen comparativo de arquitecturas evaluadas.

Iteración / Arquitectura	Validación	OOF RMSE (\$)	R^2 Score	Diagnóstico y Observaciones
1. Standard MLP	5-Fold CV	86,843.36	0.4412	Sobreajuste severo e inestabilidad
2. Wide & Deep MLP	5-Fold CV	45,907.44	0.7180	Mejora parcial por vía lineal.
3. SwiGLU-MLP	5-Fold CV	27,621.55	0.8621	Buen filtrado no lineal.
4. Ensamblas Multi-Modelo	10-Fold CV	22,723.01	0.9134	Sobre-complejidad y riesgo de s
5. Tabular ResNet (Definitivo)	10-Fold CV	24,953.61	0.8956	Modelo final seleccionado y

Las Figuras 3a y 3b ilustran el comportamiento fuera de muestra del modelo final guardado.



(a) Precios Reales vs. Predichos (\$)



(b) Análisis de Errores Residuos

Figura 3: Evaluación de desempeño fuera de muestra del modelo Tabular ResNet-MLP.

4. Discusión de Resultados

4.1. Análisis del Trade-off Complejidad vs. Sobreajuste (Overfitting)

Durante la experimentación se exploraron ensambles de múltiples semillas y arquitecturas combinadas. Si bien los ensambles complejos lograron reducir matemáticamente el RMSE en la partición de validación interna a niveles de \$22.7k, introdujeron un riesgo elevado de sobreajuste (*overfitting*) hacia el ruido aleatorio del conjunto de entrenamiento ($N = 1,168$).

Para el despliegue final se priorizó la ****parsimonia y robustez estructural****:

- Un único modelo ****Tabular ResNet-MLP**** con regularización estricta (*LayerNorm*, *Dropout* 0.20 y *Weight Decay* 2.39×10^{-4}) garantiza que las predicciones ante datos nuevos (*unseen test set*) no dependan de sobre-ponderaciones espurias.
- El repositorio se mantiene sumamente liviano: un único archivo de pesos (`model.pt`, 4.6 MB) y un único preprocesador (`pipeline.joblib`).

4.2. Análisis de Errores y Residuos

El modelo final seleccionado alcanza las siguientes métricas globales:

- **RMSE: \$24,953.61**
- **MAE: \$14,267.36**
- **R^2 Score: 0.8956** (casi el 90 % de variabilidad explicada)
- **MAPE: 8.10 %**

La distribución de residuos (Figura 3b) está centrada en cero sin sesgos sistemáticos en propiedades de rango medio y bajo (\$100k - \$400k), donde se concentra la gran mayoría del mercado inmobiliario.

5. Conclusiones

1. ****Selección del Modelo Óptimo****: Se seleccionó e implementó un único modelo Tabular ResNet-MLP por su equilibrio superior entre capacidad predictiva y resistencia al sobreajuste.
2. ****Eficiencia y Despliegue****: El proyecto cuenta con una única estructura de inferencia limpia y determinista que opera en milisegundos.
3. ****Aprendizajes Clave****: La ingeniería de variables y la regularización residual tuvieron un impacto mucho más consistente en la generalización que el aumento desmedido de parámetros.

6. Instrucciones para Inferencia en el Día de la Presentación

Para generar las predicciones sobre el dataset de prueba el día de la presentación, ejecute desde la raíz del proyecto:

```
1 python main.py predict --test_path data/pruebas/pipeline_test.csv --output_path data/pruebas/expected_output.csv
```

El script cargará automáticamente el preprocesador (`data/saved_models/pipeline.joblib`) y el modelo (`data/saved_models/model.pt`), generando el archivo CSV en el formato exacto requerido (`Id,Prediction`).