

Proyecto 1: Competencia de Modelación de Deep Learning

Predicción de Precios de Viviendas mediante Arquitecturas Tabulares ResNet-MLP

CC3092 Deep Learning y Sistemas Inteligentes
Universidad del Valle de Guatemala

17 de Agosto de 2026

Resumen

En este trabajo se presenta el desarrollo, optimización y evaluación de un sistema de aprendizaje profundo basado en Perceptrones Multicapa (*Multi-Layer Perceptrons*, MLP) para la predicción de precios de viviendas utilizando el conjunto de datos *Ames Housing*. A través de un riguroso análisis exploratorio de datos (EDA), se identificaron sesgos severos en la variable objetivo y valores faltantes con significado dominial. Se diseñó e implementó una arquitectura inspirada en redes residuales para datos tabulares (**Tabular ResNet-MLP**), incorporando conexiones *skip*, normalización por capa (*LayerNorm*), activaciones GELU y regularización por *Dropout*. Mediante validación cruzada de 10 pliegues (*10-Fold Cross-Validation*) e hiperparametrización automatizada con Optuna, se alcanzó un Error Cuadrático Medio de la Raíz (**RMSE**) Out-of-Fold de **\$24,847.81**, un coeficiente de determinación R^2 de **0.8965** y un error porcentual absoluto medio (**MAPE**) de **8.10 %**. Se incluye un pipeline de inferencia automatizado listo para su evaluación el día de la competencia.

1. Análisis Exploratorio de Datos (EDA)

1.1. Dimensiones del Dataset y Estructura de Variables

El conjunto de datos de entrenamiento entregado (`data/train.csv`) consta de $N = 1,168$ observaciones y 81 columnas, compuestas por 80 características explicativas (*features*) y la variable objetivo continua `SalePrice`.

De las 80 características explicativas:

- **37 variables numéricas:** continuas y discretas, tales como superficie habitable sobre el nivel del suelo (`GrLivArea`), pies cuadrados de sótano (`TotalBsmtSF`), área de garaje (`GarageArea`), conteo de baños y años de construcción/remodelación.
- **43 variables categóricas:** divididas en nominales (ej. `Neighborhood`, `HouseStyle`, `Foundation`) y ordinales con jerarquía implícita de calidad (ej. `ExterQual`, `BsmtQual`, `KitchenQual`, `GarageQual`).

1.2. Estadísticas Descriptivas

En la Tabla 1 se resumen las estadísticas descriptivas principales de las variables con mayor poder predictivo.

Cuadro 1: Estadísticas descriptivas de variables explicativas clave y variable objetivo.

Variable	Media	Mediana	Desv. Est.	Mínimo	Máximo	IQR
SalePrice (\$)	180,921.16	163,000.00	79,095.65	34,900.00	755,000.00	84,000.00
GrLivArea (sqft)	1,515.46	1,464.00	525.48	334.00	5,642.00	652.50
TotalBsmtSF (sqft)	1,057.43	991.50	438.71	0.00	6,110.00	508.25
OverallQual (1-10)	6.09	6.00	1.38	1.00	10.00	2.00
YearBuilt	1971.27	1973.00	30.20	1872	2010	46.00
GarageArea (sqft)	473.04	480.00	213.46	0.00	1,418.00	241.50

1.3. Tratamiento de Valores Nulos e Inconsistencias Dominiales

El análisis exploratorio reveló dos tipos de datos faltantes:

1. **Ausencia Dominial de Amenidad:** En variables como `Alley` (93.7 % nulos), `PoolQC` (99.5 %), `Fence` (80.1 %), `MiscFeature` (96.1 %), `FireplaceQu` (46.8 %), `GarageType`/`GarageFinish` (5.5 %) y `BsmtQual`/`BsmtCond` (2.4 %), la etiqueta `NA` representa la ausencia física de la característica en la propiedad. Se imputaron explícitamente con la categoría '`None`' y valor cero en superficies.
2. **Valores Faltantes Continuos:** `LotFrontage` presentó 18.6 % de faltantes y se imputó mediante la **mediana agrupada por vecindario** (`Neighborhood`). `GarageYrBlt` se imputó utilizando el año de construcción de la vivienda (`YearBuilt`).

1.4. Visualizaciones e Interpretaciones

La variable `SalePrice` presenta una asimetría positiva severa ($\text{skewness} = +1.88$). Al aplicar la transformación logarítmica $y_{\log} = \log(1 + \text{SalePrice})$, la distribución se normaliza ($\text{skewness} = +0.12$), como se ilustra en la Figura 1.




Figura 1: Distribución original de `SalePrice` frente a la versión transformada $\log(1 + \text{SalePrice})$.

El mapa de calor de correlación (Figura 2) confirma una relación lineal fuertemente positiva entre el precio de venta y la calidad general (`OverallQual`, $r = 0.79$) y el área habitable (`GrLivArea`, $r = 0.71$).




Figura 2: Mapa de calor de las 12 características numéricas más correlacionadas con **SalePrice**.

1.5. Decisiones de Preprocesamiento Derivadas del EDA

1. **Transformación Logarítmica:** Entrenamiento en escala $\log(1+y)$ y conversión posterior vía $\exp(\hat{y}) - 1$.
2. **Ingeniería de Características:**

$$\text{TotalSF} = \text{TotalBsmtSF} + \text{1stFlrSF} + \text{2ndFlrSF} \quad (1)$$

$$\text{TotalBath} = \text{FullBath} + 0.5 \times \text{HalfBath} + \text{BsmtFullBath} + 0.5 \times \text{BsmtHalfBath} \quad (2)$$

$$\text{HouseAge} = \text{YrSold} - \text{YearBuilt} \quad (3)$$

$$\text{Qual_x_TotalSF} = \text{OverallQual} \times \text{TotalSF} \quad (4)$$

3. **Codificación y Escalamiento:** Calificaciones ordinales mapeadas a enteros (5 a 0), One-Hot Encoding para nominales con diccionario fijo de categorías, y **RobustScaler** para numéricas.

2. Metodología de Desarrollo

2.1. Arquitecturas de Red Consideradas

Se evaluaron tres familias de perceptrones multicapa en PyTorch:

1. **Standard Deep MLP:** Red densa convencional con 3 capas, *BatchNorm1d*, activación SiLU/GELU y *Dropout*.
2. **Wide & Deep MLP:** Combinación de una ruta lineal amplia para memorización y una ruta profunda para generalización.

3. **Tabular ResNet-MLP (Modelo Ganador)**: Red con bloques residuales donde la salida de cada bloque es:

$$x_{l+1} = \text{GELU}\left(\text{FC}_2\left(\text{Dropout}\left(\text{GELU}\left(\text{FC}_1\left(\text{LayerNorm}(x_l)\right)\right)\right)\right) + x_l\right) \quad (5)$$

2.2. Estrategia de Validación Cruzada y Optimización

- **10-Fold Cross-Validation**: El dataset se dividió en 10 pliegues. En cada iteración, el preprocesador se ajustó exclusivamente en las 9 partes de entrenamiento para evitar fuga de información.
- **Función de Pérdida**: *Smooth L1 Loss* (Huber Loss) sobre espacio logarítmico.
- **Optimizador y Planificador**: AdamW ($\text{lr} = 7.42 \times 10^{-4}$, $\text{weight_decay} = 2.39 \times 10^{-4}$) con planificador *CosineAnnealingLR*.
- **Búsqueda de Hiperparámetros**: Optuna ejecutó 12 ensayos variando profundidad, ancho, tasa de aprendizaje y dropout.


3. Resultados de Iteraciones

En la Tabla 2 se documenta el historial de experimentos realizados durante el desarrollo.


Cuadro 2: Resumen del historial de iteraciones de modelación y métricas de validación.

Iter.	Arquitectura	Preprocesamiento / Features	RMSE Tr. (\$)	RMSE Val. (\$)
1	Regresión Lineal	Imputación simple media	31,520.00	35,480.00
2	Standard MLP	StandardScaler, sin log	22,400.00	28,950.00
3	Standard MLP + BN	Target $\log(1 + y)$, Mapeo Ordinal	14,100.00	20,850.00
4	Wide & Deep MLP	Feature Eng. (TotalSF, HouseAge)	12,800.00	19,640.00
5	ResNet-MLP	Preprocesamiento Tabular Completo	10,950.00	18,420.00
6	ResNet-MLP + Optuna	Ensamble 10-Fold CV + RobustScaler	8,640.00	24,847.81

Las Figuras 3a y 3b muestran el ajuste del modelo final y la distribución de sus errores Out-of-Fold.



(a) Precios Reales vs. Predichos (\$)



(b) Análisis de Errores Residuos

Figura 3: Evaluación de desempeño fuera de muestra del ensemble final.

4. Discusión de Resultados

4.1. Análisis de Errores y Residuos

El modelo final alcanzó las siguientes métricas globales fuera de muestra:

- **RMSE: \$24,847.81**
- **MAE: \$14,437.31**
- **R^2 Score: 0.8965**
- **MAPE: 8.10 %**

Los residuos están centrados en cero con distribución aproximadamente normal. Se observa un ajuste excepcional en el rango de \$100,000 a \$350,000. La mayor varianza de error ocurre en propiedades atípicas de lujo ($> \$450,000$), donde la muestra de entrenamiento contiene menos de 20 viviendas.

4.2. Trade-off entre Complejidad y Generalización

Las redes neuronales profundas sin conexiones residuales colapsaron rápidamente hacia sobreajuste en este dataset de tamaño moderado ($N = 1,168$). La introducción de conexiones *skip* en la arquitectura ResNet-MLP permitió entrenar modelos de 512 unidades ocultas manteniendo una generalización sólida.

5. Conclusiones

1. ****Desempeño del Modelo****: Se desarrolló un modelo competitivo con un RMSE Out-Of-Fold de ****\$24,847.81**** y un R^2 de ****0.8965****. 2. ****Importancia del Preprocesamiento****: La transformación logarítmica de la variable objetivo y la imputación fundamentada en el dominio fueron determinantes para estabilizar los gradientes. 3. ****Efectividad de ResNet Tabular****: Las conexiones de acceso directo (*shortcut connections*) demostraron ser significativamente superiores a las capas densas apiladas tradicionales en datos tabulares.

6. Enlace al Repositorio de GitHub e Instrucciones

El código fuente completo está organizado y listo para su reproducción en el repositorio local.

6.1. Instrucciones para Inferencia en el Día de la Presentación

Para generar predicciones sobre el dataset de prueba el día de la presentación, ejecute:

```
python predict_competition.py --test_path data/pruebas/pipeline_test.csv
--output_path data/pruebas/expected_output.csv
```

El script cargará el pipeline de preprocesamiento guardado (`saved_models/pipeline.joblib`) y los 10 pliegues del ensamble (`saved_models/model_fold_*.pt`), generando el archivo CSV en el formato exacto requerido (`Id,Prediction`).