

Proyecto 1: Competencia de Modelación de Deep Learning

Predicción de Precios de Viviendas mediante Ensamble Multi-Semilla de Tabular ResNet-MLP

CC3092 - Deep Learning y Sistemas Inteligentes
Universidad del Valle de Guatemala

Agosto 2026

Resumen

Este informe presenta el desarrollo de un sistema de aprendizaje profundo basado en Redes Neuronales Multicapa (*Multi-Layer Perceptrons*) para la predicción de precios de venta de viviendas residenciales en Ames, Iowa. A través de un riguroso análisis exploratorio de datos, se implementó un pipeline de preprocesamiento e ingeniería de variables dominiales que incluye agregaciones de superficie, edades efectivas e interacciones no lineales. Se evaluaron arquitecturas estándar, Wide & Deep y Tabular ResNet-MLP. El modelo final consiste en un ensamble multi-semilla de 30 modelos neuronales Tabular ResNet (3 semillas independientes evaluadas en validación cruzada de 10 pliegues), optimizado con *Smooth L1 Loss* (Huber) en escala logarítmica. El ensamble alcanzó el mejor error cuadrático medio fuera de muestra (OOF RMSE) de **\$22,723.01**, un coeficiente de determinación R^2 de **0.9134** y un error relativo (MAPE) de **7.61 %**, superando ampliamente el punto de referencia de \$24,847.81 y maximizando la precisión en la métrica oficial de la competencia.

Índice

1. Análisis Exploratorio de Datos (EDA)	2
1.1. Dimensiones del Dataset y Distribución de Tipos de Variables	2
1.2. Análisis de la Variable Objetivo: SalePrice	2
1.3. Variables Más Correlacionadas e Ingeniería de Características	2
1.4. Decisiones de Preprocesamiento Basadas en el EDA	3
2. Metodología de Desarrollo	4
2.1. Arquitectura Ganadora: Tabular ResNet-MLP	4
2.2. Estrategia de Validación Cruzada y Ensamble Multi-Semilla	4
3. Resultados y Comparativa de Modelos	4
4. Discusión de Resultados	5
4.1. Análisis de Errores y Residuos	5
4.2. Trade-off entre Complejidad y Generalización	5
5. Conclusiones	5
6. Instrucciones para Inferencia en el Día de la Presentación	5

1. Análisis Exploratorio de Datos (EDA)

1.1. Dimensiones del Dataset y Distribución de Tipos de Variables

El conjunto de entrenamiento provisto contiene un total de 1,168 observaciones y 81 columnas:

- **Identificador:** Columna Id.
- **Variable Objetivo:** SalePrice (continua positiva).
- **Variables Predictoras:** 79 características, distribuidas en 36 variables numéricas continuas/discretas y 43 variables categóricas (nominales y ordinales).

1.2. Análisis de la Variable Objetivo: SalePrice

La distribución original de SalePrice presenta una asimetría positiva sustancial (skewness = 1.88) y colas pesadas (kurtosis = 6.53), con precios que oscilan entre \$34,900 y \$745,000 (media: \$181,441; mediana: \$165,000). Para adecuar los datos al entrenamiento de redes neuronales y estabilizar la varianza del gradiente, se aplicó la transformación logarítmica:

$$y_{\text{trans}} = \log(1 + \text{SalePrice}) \quad (1)$$

La Figura 1 ilustra la distribución original y la distribución normalizada tras la transformación.




Figura 1: Distribución de la variable objetivo antes y después de la transformación logarítmica.

1.3. Variables Más Correlacionadas e Ingeniería de Características

Las variables numéricas con mayor correlación lineal con el precio de venta son OverallQual ($r = 0.79$), GrLivArea ($r = 0.71$), GarageCars ($r = 0.64$), GarageArea ($r = 0.62$), TotalBsmtSF ($r = 0.61$) y 1stFlrSF ($r = 0.60$).




Figura 2: Matriz de correlación de las principales variables numéricas con **SalePrice**.

1.4. Decisiones de Preprocesamiento Basadas en el EDA

1. **Imputación de Valores Faltantes por Dominio:** En variables como **Alley**, **BsmtQual**, **GarageType**, **FireplaceQu** y **PoolQC**, los valores nulos (NA) indican la ausencia física del elemento. Fueron imputados como la categoría explícita 'None'.
2. **Imputación de LotFrontage:** Mediana agrupada por vecindario (**Neighborhood**).
3. **Ingeniería de Características:**

$$\text{TotalSF} = \text{TotalBsmtSF} + \text{1stFlrSF} + \text{2ndFlrSF} \quad (2)$$

$$\text{TotalBath} = \text{FullBath} + 0.5 \times \text{HalfBath} + \text{BsmtFullBath} + 0.5 \times \text{BsmtHalfBath} \quad (3)$$

$$\text{TotalPorchSF} = \text{WoodDeckSF} + \text{OpenPorchSF} + \text{EnclosedPorch} + \text{3SsnPorch} + \text{ScreenPorch} \quad (4)$$

$$\text{HouseAge} = \max(0, \text{YrSold} - \text{YearBuilt}) \quad (5)$$

$$\text{RemodAge} = \max(0, \text{YrSold} - \text{YearRemodAdd}) \quad (6)$$

$$\text{Qual_x_TotalSF} = \text{OverallQual} \times \text{TotalSF} \quad (7)$$

4. **Codificación y Escalamiento:** Calificaciones ordinales mapeadas a enteros (5 a 0), One-Hot Encoding para nominales con diccionario cerrado, y **RobustScaler** para numéricas con transformación $\log(1 + x)$ para variables asimétricas ($\text{skew} > 0.75$).

2. Metodología de Desarrollo

2.1. Arquitectura Ganadora: Tabular ResNet-MLP

La arquitectura Tabular ResNet-MLP implementa bloques residuales con normalización por capa (*LayerNorm*), activaciones GELU y conexiones de acceso directo (*skip connections*):

$$x_{l+1} = \text{GELU}\left(\text{FC}_2\left(\text{Dropout}\left(\text{GELU}\left(\text{FC}_1\left(\text{LayerNorm}(x_l)\right)\right)\right) + x_l\right)\right) \quad (8)$$

Esta formulación previene la degradación del gradiente y estabiliza el aprendizaje a través de 512 unidades ocultas y *Dropout* del 20 %, conectadas directamente a la capa de salida lineal.

2.2. Estrategia de Validación Cruzada y Ensamble Multi-Semilla

- **10-Fold Cross-Validation:** El dataset se dividió en 10 pliegues independientes. El preprocesador se ajustó estrictamente dentro de cada partición para evitar fuga de información.
- **Función de Pérdida:** *Smooth L1 Loss* (Huber Loss) en escala logarítmica.
- **Optimizador y Planificador:** AdamW ($\text{lr} = 7.42 \times 10^{-4}$, $\text{weight_decay} = 2.39 \times 10^{-4}$) con planificador *CosineAnnealingLR* ($T_{\text{máx}} = 150$).
- **Ensamble Multi-Semilla (30 Modelos):** Promedio de las predicciones de los modelos entrenados con 3 semillas aleatorias independientes (42, 123, 2024) y 10 pliegues cada una.


3. Resultados y Comparativa de Modelos

En la Tabla 1 se detalla la progresión del error Out-Of-Fold en las distintas fases de modelación.


Cuadro 1: Resumen comparativo de arquitecturas y modelos evaluados (ordenados por RMSE).

Arquitectura / Ensamble	Estrategia de Validación	OOF RMSE (\$)	R^2 Score
Standard MLP	5-Fold CV	86,843.36	0.4412
Wide & Deep MLP	5-Fold CV	45,907.44	0.7180
Tabular ResNet-MLP (1 Semilla)	10-Fold CV	24,847.81	0.8965
Ensamble Multi-Semilla ResNet (30 Modelos)	10-Fold CV (3 Seeds)	22,723.01	0.9134

Las Figuras 3a y 3b muestran el ajuste del ensamble final y la distribución de sus residuos Out-of-Fold.



(a) Precios Reales vs. Predichos (\$)



(b) Análisis de Errores Residuos

Figura 3: Evaluación de desempeño fuera de muestra del ensemble campeón.

4. Discusión de Resultados

4.1. Análisis de Errores y Residuos

El ensemble final alcanzó las siguientes métricas globales fuera de muestra:

- **RMSE: \$22,723.01**
- **MAE: \$13,177.30**
- **R^2 Score: 0.9134**
- **MAPE: 7.61 %**

Los residuos se encuentran centrados en cero con dispersión simétrica. El error porcentual promedio (MAPE) de 7.61 % y el RMSE de \$22,723.01 superan con claridad el punto de referencia de \$24,847.81.

4.2. Trade-off entre Complejidad y Generalización

Las redes neuronales densas convencionales sobreajustan rápidamente en datos tabulares de dimensión moderada. El uso de conexiones residuales con LayerNorm y el promediado de 3 semillas aleatorias reduce sustancialmente la varianza del estimador, garantizando robustez y generalización ante el conjunto de prueba de la competencia.

5. Conclusiones

1. ****Máximo Desempeño en RMSE****: El ensemble multi-semilla ResNet alcanzó un RMSE récord de ****\$22,723.01****, superando el modelo de referencia por más de \$2,100. 2. ****Explicabilidad y Calidad de Ajuste****: Con un R^2 de ****0.9134****, el modelo explica más del 91 % de la variabilidad de precios. 3. ****Pipeline Determinista y Listo para Presentación****: Todo el código de inferencia está consolidado en `main.py` y reproduce fielmente las predicciones.

6. Instrucciones para Inferencia en el Día de la Presentación

Para generar las predicciones sobre el dataset de prueba el día de la presentación, ejecute desde la raíz del proyecto:

```
1 python main.py predict --test_path data/pruebas/pipeline_test.csv --output_path  
   data/pruebas/expected_output.csv
```

El script cargará automáticamente el preprocesador (`data/saved_models/pipeline.joblib`) y los 30 modelos del ensamble (`data/saved_models/model_resnet_seed_*.pt`), generando el archivo CSV en el formato exacto requerido (`Id,Prediction`).